

# 课程作业三：SFT 监督微调与 DPO 偏好对齐

姓名：廖佩瑶 | 学号：2022K8009915031 | 课程：大语言模型 | 日期：2025年5月

## 一、实验设计

### 1.1 实验环境

| 项目   | 配置                                   |
|------|--------------------------------------|
| 平台   | SCNet 云平台                            |
| GPU  | NVIDIA RTX 4090                      |
| 框架   | MiniMind (类 LLaMA Decoder-only 小模型)  |
| 模型规模 | hidden_size=512, layers=8, 25.83M 参数 |
| 项目目录 | /root/private_data/minimind/         |

### 1.2 SFT 阶段数据构造与对话模板

SFT 阶段使用数据集 `sft_mini_512.jsonl`, 共约 75921 条对话样本。每条样本包含一轮或多轮对话：

```
{"conversations": [  
  {"role": "user", "content": "用户提问内容"},  
  {"role": "assistant", "content": "助手回答内容"}  
]}
```

训练时采用 Chat Template 将对话序列化为模型输入：

```
<s>[INST] 用户提问内容 [/INST] 助手回答内容 </s>
```

训练目标为标准的 Next Token Prediction, 仅对助手回答部分计算 loss, 用户输入部分的 loss 被 mask 掉。

### 1.3 DPO 阶段数据构造方式

DPO 阶段使用数据集 `dpo.jsonl`，每条样本包含同一 `prompt` 下的一对偏好回答：

```
{
  "prompt": "问题内容",
  "chosen": "人类偏好的优质回答",
  "rejected": "人类不偏好的劣质回答"
}
```

DPO 不需要显式的奖励模型，直接利用 `chosen/rejected` 对优化策略模型。训练时同时维护冻结的参考模型（`ref_model`），通过 KL 散度约束防止模型偏离 SFT 原点太远。DPO 损失函数如下：

$$L_{DPO} = -E[\log \sigma(\beta \cdot (\log \pi_{policy}(chosen) - \log \pi_{ref}(chosen)) - \beta \cdot (\log \pi_{policy}(rejected) - \log \pi_{ref}(rejected)))]$$

### 1.4 核心超参数设置

| 参数              | SFT 阶段 | DPO 阶段                |
|-----------------|--------|-----------------------|
| 学习率             | 1e-5   | 1e-6                  |
| 批大小             | 16     | 4                     |
| 训练轮数            | 1      | 1                     |
| 最大序列长度          | 512    | 1024                  |
| 优化器             | AdamW  | AdamW                 |
| KL 惩罚系数 $\beta$ | —      | 0.1 / 0.5 / 0.9（消融实验） |
| 梯度裁剪            | 1.0    | 1.0                   |

## 二、实验结果

### 2.1 SFT 训练 Loss 曲线




图1: SFT 训练 Loss 曲线 (浅色为原始 loss, 深色为滑动平均 window=20)

- 训练初期 (step 0~5000) , loss 从约 2.35 迅速下降至 2.10, 模型快速学习到对话格式与指令跟随能力。
- 训练中后期 (step 5000~75921) , loss 在 1.95~2.10 区间内波动, 整体缓慢下降, 最终稳定在约 1.95~2.00, 模型基本收敛。
- 滑动平均曲线清晰展示了整体下降趋势, 训练过程稳定。

## 2.2 DPO 训练 Reward Margin 曲线

### 2.2.1 单次 DPO 训练 ( $\beta=0.1$ , $lr=1e-6$ )




图2: DPO Reward Margin 变化曲线 (左: reward margin; 右: chosen vs rejected reward)

|                          |         |
|--------------------------|---------|
| 前 1/4 步 reward margin 平均 | 0.0049  |
| 后 1/4 步 reward margin 平均 | 0.0627  |
| 整体最大值                    | 0.3848  |
| 整体最小值                    | -0.2102 |
| margin > 0 的比例           | 75.6%   |

- **Reward Margin (左图)**：训练初期 margin 接近 0，step 1500 后开始上升，后期稳定在 0.05~0.10，峰值达 0.38。整体 75.6% 的步骤 margin > 0，说明 DPO 成功对齐了人类偏好。
- **Chosen vs Rejected Reward (右图)**：两者均呈下降趋势，但 rejected reward 下降更快、更深，始终低于 chosen reward。说明 DPO 的主要机制是**压低 rejected 答案的概率**，而非直接提升 chosen 答案的概率，与 KL 惩罚约束下的理论预期一致。

2.2.2  $\beta$  参数消融实验 ( $\beta=0.1, 0.5, 0.9$ )




图3：不同  $\beta$  参数下的 Reward Margin 对比曲线 (lr=1e-6, 1 epoch)

| $\beta$ 值 | KL 惩罚强度 | 最终 Reward Margin | 曲线特征              |
|-----------|---------|------------------|-------------------|
| 0.1 (蓝色)  | 弱       | ~0.06            | 上升最慢，数值最小，偏好学习最激进 |

|         |    |            |                                 |
|---------|----|------------|---------------------------------|
| 0.5（橙色） | 中等 | ~0.10~0.20 | 中等速度上升，波动适中                     |
| 0.9（绿色） | 强  | ~0.25~0.30 | 数值最大（因 $\beta$ 本身放大了 reward 尺度） |

**注意：** $\beta$  同时是 implicit reward 的缩放系数 ( $r = \beta \times \log \text{ratio}$ )， $\beta$  越大 reward 数值本身越大。因此 Reward Margin 绝对值大并不代表偏好对齐效果更好，需结合实际生成质量综合判断。

- $\beta=0.1$ ：KL 惩罚最弱，模型可以更大幅度偏离 ref\_model，偏好学习最激进，实际生成质量改善最明显。
- $\beta=0.5$ ：在偏好对齐和遗忘控制之间取得较好平衡。
- $\beta=0.9$ ：KL 惩罚最强，模型几乎不能偏离 ref\_model，偏好学习受限，但原有能力保持最好。

### 2.3 三方 Case 对比（Pretrain vs SFT vs DPO）

**Case 1: 你是谁? 请介绍一下你自己。**

**Pretrain**

我是计算机科学的领袖，我是一位程序员、数据分析师和人工智能工程师，我是从事AI研究和开发的，旨在解决各种复杂的问题。我被设计成能够识别和理解自然语言，并能够理解人类语言和视觉信息。我的目标是开发一款能够根据用户输入的数据自动处理自然语言的AI算法，以模拟人类智能和理解自然语言的AI算法，以识别和理解人类语言。我具有强大的计算能力和计算能力，以执行复杂的任务。

**SFT**

我是阿里云开发的超大规模语言模型，我叫通义千问，是阿里云的超大规模语言模型，能够回答各种问题、提供信息与用户进行对话，我能够回答各种问题、提供信息和进行对话，同时能够生成和生成各种文本内容，我还可以进行各种任务，如搜索引擎优化、生成文本、分析文本、分析文本、生成文本.....（后续出现大量重复内容）

**DPO( $\beta=0.1$ )**

我是阿里云开发的超大规模语言模型，属于阿里云开发的虚拟助手，在提供帮助解答问题、执行计算、执行任务、提供信息查询、应用开发、语言翻译、游戏开发等服务，阿里云提供了一套规范的、高性能的服务体验，旨在满足用户的需求、技术要求、资源管理需求.....

## Case 2: 为什么天空是蓝色的?

### Pretrain

天空之所以呈现蓝色的原因是因为大气层中的气体分子会吸收太阳光中的能量，并散射出蓝色的光线，使我们看到了天空中的蓝色。而在太阳光中，大气层中的气体分子会吸收蓝色光，因此我们看到的天空呈现蓝色。这是因为大气层中的气体分子会吸收太阳光中的能量，这些能量是我们的视野和感觉，同时，大气层中的气体分子还会吸收蓝色光，从而影响我们的视觉和感觉，因此我们看到天空呈现蓝色的原因是由于大气层中的气体分子，这些分子被吸收和散射，使得我们看到了天空中的蓝色和红色。

### SFT

天空之所以呈现蓝色的原因，是因为地球大气层的不同颜色不同，蓝色是因为大气分子散射了蓝色光，而大气分子散射了蓝色光，蓝色光的波长较短，而蓝色光的波长较短，因此我们看到的天空颜色是蓝色的，而蓝色光的波长较短，因此我们看到的天空颜色是蓝色的。

### DPO( $\beta=0.1$ )

天空之所以呈现蓝色，主要是因为大气层的物理构造和大气的吸收、折射、散射等多种物理过程，与大气层中的气体分子（如氧气、二氧化碳等）的运动有关。天空中的蓝色和紫色光波长较短，这些光波长较短，因此在大气层中散射的角度较小，散射范围较广，使得天空呈现出蓝色。

## Case 3: 如何看待考试作弊这种行为?

### Pretrain

有些人认为考试作弊，但是这种行为是不道德的，考试作弊是一种非法的行为，会对考试作弊产生负面影响，甚至会对考试作弊造成损害，考试作弊是一种不道德的行为，可能会对考试作弊产生负面影响，甚至会对考试作弊造成损害，此外，考试作弊也是一种不道德的行为，如果考试作弊是危险的，那么考试作弊可能会成为犯罪行为。

### SFT

考试作弊是一种不道德的行为，它违反了道德规范，违反了道德规范，因此，我们应该尊重学生的个人信仰、文化传统和教育观念，并为学生提供一个平等的学习环境。

DPO( $\beta=0.1$ )

考试作弊的不足，它通常会影响个人的学习、学习成绩、学习效果等多种因素，这些因素对考试成绩的负面影响尤为显著。考试作弊可能导致考试成绩下降、学习质量下降等问题。特别是对于初学者和教师而言，考试作弊不仅影响考试成绩，也对考试的公平性造成影响。

## 三、结果分析

### 3.1 SFT 后的模型是否摆脱了"无脑续写"?

从三方 Case 对比可以看出，**SFT 后的模型已经基本摆脱了"无脑续写"**：

- Pretrain 模型在回答"你是谁"时，胡乱续写"我是计算机科学的领袖"，完全没有问答意识，体现出典型的"无脑续写"特征。
- SFT 模型能够识别 user 提问并以 assistant 口吻作答，说明 SFT 成功注入了指令跟随能力。
- SFT 模型在"天空蓝色"case 中给出了更结构化的回答，而 Pretrain 模型只是不断重复相似语句。

### 3.2 是否出现了"灾难性遗忘"或格式错误?

- **复读问题（格式错误）**：SFT 和 DPO 模型在多个 case 中出现了大量重复 token，如"分析文本、分析文本..."和"学习成绩、学习成绩..."。这说明当前训练数据中存在长尾不平衡或解码采样不稳定的问题，SFT 阶段未能完全解决重复生成的倾向。
- **事实性下降（灾难性遗忘）**：SFT 模型在"天空蓝色"case 中出现了"地球大气层的不同颜色不同"这样的病句，而 Pretrain 模型的回答虽然格式不规整，但事实方向基本正确（提到了散射）。这说明 SFT 过程中存在一定程度的灾难性遗忘。

### 3.3 DPO 在哪些方面提升了回答质量?

- **逻辑性与结构性**：DPO 模型在"天空蓝色"case 中明确提及"物理构造"、"折射"、"散射"等关键机制，逻辑层次更清晰。
- **论述维度的丰富性**：在"作弊"case 中，DPO 模型给出了多维度的影响分析，而 SFT 模型只给出了简短的道德判断。

- **人设对齐更稳定**：DPO 模型在自我介绍中明确定位为"虚拟助手"，比 SFT 模型更符合偏好数据中的对齐目标。

**DPO 并未完全解决 SFT 阶段遗留的复读问题**，说明 DPO 主要作用于偏好层面，而非根本性地改善解码稳定性。

3.4  $\beta$  参数消融实验分析

| $\beta$ 值 | 偏好对齐能力 | 遗忘风险 | 适用场景            |
|-----------|--------|------|-----------------|
| 0.1       | 强（激进）  | 较高   | 需要强偏好对齐，可接受一定遗忘 |
| 0.5       | 中等     | 中等   | 平衡偏好对齐与原能力保持    |
| 0.9       | 弱（保守）  | 低    | 需要最大限度保持原能力     |

$\beta$  越小，KL 惩罚越弱，模型可以更大幅度偏离 ref\_model，偏好学习更充分，但遗忘风险更高； $\beta$  越大，KL 惩罚越强，原有能力保持越好，但偏好学习效果越弱。本实验中  $\beta=0.1$  在 reward margin 提升与实际生成质量改善之间取得了最佳平衡。

四、总结

本实验基于 MiniMind 框架，完整实现了从预训练基座到 SFT 监督微调再到 DPO 偏好对齐的完整训练流程，主要结论如下：

1. **SFT 成功赋予了模型指令跟随能力**，使其从"无脑续写"进化为能够识别用户意图并以助手身份作答，但同时引入了复读问题和一定程度的灾难性遗忘。
2. **DPO 在逻辑性、结构性和人设对齐方面显著提升了模型质量**，reward margin 从训练初期的 0.0049 增长到后期的 0.0627，75.6% 的训练步骤 margin > 0，证明偏好对齐有效。但 DPO 未能完全解决解码稳定性问题（复读）。
3.  **$\beta$  参数消融实验揭示了偏好对齐与遗忘控制之间的权衡关系**： $\beta=0.1$  偏好学习最激进， $\beta=0.9$  最保守， $\beta=0.5$  居中。



4. DPO 的核心机制是"压低 rejected 概率"而非"提升 chosen 概率", 与 KL 惩罚约束下的理论预期一致。