

课程作业二：Pre-training 预训练实验报告

姓名：廖佩瑶 | 学号：202422K8009915031 | 日期：2026-05-05

一、实验设计

1.1 数据集

- 数据集**：MiniMind 预训练语料 (pretrain_hq.jsonl)，中文为主的高质量预训练数据。
- 样本数量**：1,270,238 条文本。
- 截断长度 (max_seq_len)**：512 tokens。
- Tokenizer**：MiniMind 自带 BPE 分词器 (词表大小约 6400)。

1.2 模型架构

参数	取值	说明
hidden_size	512	隐藏层维度
num_hidden_layers	8	Transformer 层数
num_attention_heads	8 (默认)	注意力头数
max_position_embeddings	512	最大位置长度
架构类型	Decoder-only Transformer	类 LLaMA 结构 (RMSNorm + RoPE + SwiGLU)


总参数量	≈ 25.83 M	Small 规模
------	-----------	----------

1.3 训练超参

超参	取值
Batch Size	32
Learning Rate	5e-4 (cosine 调度)
Epochs	1
训练总步数	39,695 步
优化器	AdamW
损失函数	Cross-Entropy (标准语言建模 Loss)
硬件	NVIDIA RTX 4090 (SCNet 云平台)

二、实验结果

2.1 训练 Loss 曲线



关键指标：

- 初始 Loss: 7.6439
- 最终 Loss (最后 20 步均值) : 2.2030
- 训练过程最低 Loss: 1.9296
- 共记录 794 个数据点 (每 50 步打印一次)

2.2 文本续写示例

以下展示 3 个文本前缀及预训练模型的续写结果，生成参数: `temperature=0.85`, `top_p=0.85`, `max_new_tokens=200`。

示例 1

 **输入前缀:** 北京是中国的首都,

 **模型续写:** 北京是中国的首都, 而张家界的领袖, 则是中国的皇家界领袖, 如汉朝、宋、元等, 在中国的文化、经济、经济等方面都具有重要的地位。张家界的领袖, 如汉朝、汉朝、宋朝、宋朝、元等, 在中国的文化、经济、经济等方面都具有重要的地位。1. 张家界的领袖, 如汉朝、宋、元等, 在中国的文化、经济、经济等方面都有着重要的地位。张家界的领袖, 如汉朝、宋朝、宋朝、元等, 在中国的文化、经济等方面都具有重要的地位。2. 张家界的领袖, 如汉朝、宋朝、元等, 在中国的文化、经济、经济等方面都有着重要的地

示例 2

 **输入前缀:** 人工智能技术近年来发展迅速,

 **模型续写:** 人工智能技术近年来发展迅速, 主要是为了开发出更加智能化和高效的机器学习和自然语言处理技术。这些技术的应用可以极大地提高人类的生活水平和工作效率。1. 什么是人工智能技术? 2. 人工智能技术的开发是否会带来巨大的变革? 3. 人工智能技术在哪些领域有广泛应用? 4. 人工智能技术在哪些领域有应用? 5. 人工智能技术的快速发展有哪些潜力?

示例 3

 **输入前缀:** 在遥远的古代, 有一位年轻的书生,

 **模型续写：**在遥远的古代，有一位年轻的书生，他是唯一一位出版社的记者。他在当今社会里扮演着重要角色，并以其对社会现实和文学的认知。他对当今社会的认识有着深远的影响。他曾在世界各地广受欢迎的书籍、小说和电影等书籍中创造出自己的作品。在小说中，他结交了许多其他的朋友，并从中获得了许多启示。他也成为了许多其他书籍和书籍中的核心组成部分，并对世界的历史和文化产生了深远的影响。他的作品不仅在历史上展示出自己的文学价值，也在历史上有着深远的影响。在古代，他曾在历史上担任过重要的角色，并对世界历史和文化产生了深远的影响。

三、结果分析

3.1 收敛性分析

从 Loss 曲线可以看出，模型 Loss 从初始 **7.64** 快速下降至 **2.20** 左右，整体下降趋势可分为三个阶段：

1. **急速下降期 (0 ~ 2000 步)**：Loss 从 7.6 迅速降到 3.5 左右，模型快速学习到 token 频率分布与基本语言统计规律。
2. **稳步下降期 (2000 ~ 15000 步)**：Loss 从 3.5 缓慢下降至 2.5 附近，模型开始学习更复杂的句法结构与语义关联。
3. **平稳收敛期 (15000 ~ 39695 步)**：Loss 在 2.2 ~ 2.4 之间小幅波动，曲线趋于平缓，模型已基本达到 1 epoch 内的收敛状态。

在 1 个 epoch 内 Loss 没有出现明显的**梯度爆炸或剧烈震荡**，说明学习率 ($5e-4 + \text{cosine}$ 调度) 和 batch size 设置合理。原始 Loss 曲线 (浅蓝) 存在小幅高频抖动，这是 mini-batch 训练的正常噪声；经 20 步滑动平均后 (红色) 曲线非常平滑。若继续训练更多 epoch 或增大数据量，Loss 仍有进一步下降空间，但边际收益会递减。

3.2 生成文本质量分析

对生成的续写文本进行观察，可以得到以下结论：

- **已学会基本断句与标点**：所有生成文本都正确使用了句号、逗号、问号等标点，句子结构完整，未出现乱码或符号堆砌。

- **词语搭配自然**：如"皇家界领袖""文化、经济等方面"开发出更加智能化和高效的"等搭配符合中文表达习惯。
- **掌握了一定的领域风格**：在"人工智能"前缀下生成科技类描述，在"古代书生"前缀下生成叙事类文本，说明模型从语料中学到了一定的**语域感知能力**。
- **存在重复（复读）现象**：例如第一例中"张家界的领袖，如汉朝、宋朝....."出现循环重复，这是小模型 + 短训练时的典型问题，可通过引入 repetition_penalty 或继续训练缓解。
- **缺乏长程逻辑与事实正确性**：如"北京是中国的首都"被续写为关于"张家界"的内容，出现明显的语义漂移；这是**预训练模型的固有局限**——它只学了"下一个 token 是什么最可能"，并不具备指令遵从和事实约束能力。

结论：预训练阶段成功让模型学会了 基本的断句、标点使用与局部词语搭配，具备了"说人话"的能力，但要做到"答非所问"问题的解决和事实一致性，需要后续 SFT（监督微调）和 RLHF/DPO 等对齐阶段。

3.3 探索性思考（Scaling Law 雏形）

本次实验使用 25.83M 参数的小模型在 127 万条数据上训练 1 epoch，最终 Loss 收敛于 2.2 左右。根据 Scaling Law (Kaplan et al., 2020; Chinchilla, 2022) 的经验规律，模型 Loss 与参数量 N 、数据量 D 满足近似幂律关系：

$$L(N, D) \approx A \cdot N^{-\alpha} + B \cdot D^{-\beta} + L_{\infty}$$

预期若将模型层数从 8 加倍至 16（参数量约翻倍至 ~50M），在相同数据量下，最终 Loss 会进一步下降约 0.1 ~ 0.3，但训练时间和显存开销也会近似翻倍。在受限算力下，**提升数据质量与多样性**往往比单纯加深网络收益更高。